

UNIVERSIDAD DE CÓRDOBA

Facultad de Ciencias

Grado de Física

Trabajo Fin de Grado

Aplicación de técnica machine learning en la predicción de las concentraciones de polen en la provincia de Córdoba

Código del TFG: **FS24-025-FSC**

Tipo de TFG: **Trabajo teórico-práctico**

Autor: Sylvain Sylvestre Icaro Hamers



9 de septiembre de 2025

 UNIVERSIDAD DE CORDOBA	ANEXO XII Facultad de Ciencias Declaración de originalidad	
---	--	---

D./D.^a Con DNI

Estudiante del Grado en


DECLARA

Que es el autor y asume la originalidad, entendida esta última en el sentido de que no ha utilizado fuentes sin citarlas debidamente, del Trabajo Fin de Grado titulado:

Asimismo, es consciente de que el plagio, entendido como la presentación de un trabajo u obra hecho por otra persona como propio o la copia de textos sin citar su procedencia, conllevará automáticamente la calificación numérica de cero, y que esta consecuencia se entiende sin perjuicio de las responsabilidades disciplinarias en las que pudieran incurrir si plagia, al tener la consideración de infracción muy grave, de conformidad con el artículo 11.g de la Ley 3/2022, de Convivencia Universitaria y artículo 8.g del Reglamento 5/2023 de Convivencia Universitaria de la Universidad de Córdoba.

En Córdoba, a de de

El/la Estudiante
Sylvain Sylvestre Icaro Hamers

Fdo. 

Sr./Sra. Decano/a de la Facultad de Ciencias de la Universidad de Córdoba.

Agradecimientos

Me gustaría expresar mi agradecimiento a mis tutores, Miguel Ángel Hernández Ceballos y Beatriz Ruiz Granados por su gran ayuda y aportación a este trabajo. Por su paciencia y apoyo constante a lo largo de estos últimos meses de trabajo. Me siento afortunado de haber tenido estos tutores y su alto compromiso me ha resultado motivador para esforzarme al máximo.

También me gustaría agradecer a mi familia por confiar en mí y apoyarme sin importar las circunstancias.

Finalmente quiero agradecer a mis amigos por ayudarme a aprobar varias asignaturas y convertir estos cinco años de carrera en una experiencia agradable y memorable.

Índice general

Índice general	3
Índice de figuras	4
Índice de tablas	5
Resumen. Palabras clave	6
Abstract. Keywords	7
1. Introducción	8
2. Objetivos	11
3. Metodología	12
3.1. Zona de estudio	12
3.2. Datos	13
3.2.1. Datos de polen	13
3.2.2. Datos meteorológicos	15
3.3. <i>Machine learning</i>	16
3.3.1. Preprocesamiento de datos	16
3.3.2. Técnicas de <i>machine learning</i> utilizadas	18
3.3.3. Optimización	21
3.4. Estadísticos utilizados	25
4. Resultados	27
4.1. Evolución temporal de las concentraciones de polen	27
4.2. Comparativa de parámetros temporales	30
4.3. Comparativa de parámetros de concentración	32
4.4. Discusión de los resultados y cálculo del índice total de predicción . . .	35
Conclusiones	37
Bibliografía	38

Índice de figuras

3.1. Zona de estudio	12
3.2. Diagrama <i>Wind Rose</i> de Córdoba	13
3.3. Ejemplo de parámetros usados	15
3.4. Figura representativa de la normalización de los datos	17
3.5. Figura representativa de los componentes principales	18
3.6. Representación visual del algoritmo <code>KNeighborsRegressor</code>	19
3.7. Representación visual del algoritmo <code>RandomForestRegressor</code>	20
3.8. Representación visual del algoritmo <code>MLPRegressor</code>	21
4.1. Evolución temporal	28
4.2. Gráfica comparativa de los parámetros temporales	31
4.3. Comparación de los valores NMB y NME de los parámetros temporales	32
4.4. Gráfica comparativa de los parámetros de concentración	33
4.5. Comparación de los valores NMB y NME de los parámetros de concentración	34

Índice de tablas

4.1. Coeficientes de determinación de las evoluciones temporales	29
4.2. Coeficientes de determinación de las evoluciones temporales a lo largo de los años	29
4.3. Rendimiento de cada modelo en base a los errores (NMB) y (NME) . .	36

Resumen

El polen de gramíneas es una de las principales causas de alergia en el sur de la Península Ibérica. Por este motivo, es importante evaluar nuevas herramientas que ayuden a predecir las concentraciones de este tipo de polen. El objetivo de este estudio es evaluar varios algoritmos de *machine learning* en la predicción de la concentración de polen de Poaceae en la ciudad de Córdoba, tomando como referencia las concentraciones diarias de 23 años (2001-2023). Los algoritmos evaluados son KNeighborsRegression, RandomForestRegressor y MLPRegressor. Estos algoritmos son optimizados mediante técnicas de validación cruzada y evaluados mediante el cálculo de estadísticos como *Normalized Mean Bias* (NMB) y el *Normalized Mean Error* (NME). La comparativa de varios parámetros temporales y de concentración de polen proporciona una visión completa de la fiabilidad de los diferentes métodos. Los resultados muestran que el MLPRegressor es el algoritmo que mejor rendimiento presenta en la predicción de concentraciones de polen diario de gramíneas en Córdoba.

Palabras clave: Polen, Poaceae, Córdoba, *Machine Learning*, *Nearest Neighbors*, *Random Forest*, Redes Neuronales

Abstract

Gramineae pollen is a major cause of allergy in Iberian Peninsula's south. Therefore, it is important to research new tools to improve the forecast of this type of pollen. This study's objective is the evaluation of multiple machine learning algorithms in the forecast of Poaceae pollen concentration in the city of Cordoba. The algorithms being tested are KNeighborsRegression, RandomForestRegressor and MLPRegressor. These algorithms are optimized through cross-validation techniques and scored via comparison with real pollen concentration measurements using statistical tools like Normalized Mean Bias (NMB) and Normalized Mean Score (NME). The comparisons using temporal and concentration parameters gives a complete insight on the model's performance. Overall, MLPRegressor is the algorithm that has shown the best performance in terms of gramineae pollen forecast in Córdoba.

Keywords: Pollen, Poaceae, Córdoba, Machine Learning, Nearest Neighbors, Random Forest, Neural Networks

Introducción

El polen es la fuente de alergias más común en España [1], ya que, aproximadamente, el 25 % de la población, según la Sociedad Española de Alergología e Inmunología Clínica (SEAIC), sufre algún tipo de alergia al polen. Dentro de esta generalidad, hay variaciones de unas regiones a otras, provocadas principalmente por las diferencias en cuanto al tipo y cantidad de emisión de polen a la atmósfera y condiciones meteorológicas/climatológicas. Las zonas más secas, como el centro y sur, tienden a experimentar mayores tasas de alergia al polen, especialmente durante la primavera, mientras que las zonas del norte, más húmedas, presentan una menor tasa. En Andalucía, región ubicada al sur, se estima que alrededor del 25 % de la población sufre de alergias respiratorias, habiendo aumentado el porcentaje de andaluces que padecen de conjuntivitis o rinitis alérgica del 4.06 % en 2016 al 9.39 % en 2021 [2].

Las plantas de gramíneas y olivo son las que causan mayor incidencia de alergia y polinosis en España, según la SEAIC, siendo el polen generado por las primeras el que se ha tomado como referencia en este estudio. Las gramíneas (Poaceae) son una familia de plantas herbáceas, con aproximadamente 12.000 especies identificadas [3], entre las que se incluyen el trigo, el arroz, el maíz, la avena, entre otras, así como especies utilizadas en jardinería y paisajismo, como el césped y el bambú. Si bien su importancia para la población es innegable, su elevada presencia provoca elevados niveles de concentración de granos de polen en el aire. En este sentido, se establecen unos valores umbrales de concentración de polen de gramíneas referidos a los niveles que se consideran peligrosos para las personas alérgicas. Según la Red Española de Aerobiología, para periodos de 24 horas se establece 50 granos de polen/m³ como el nivel más elevado, mientras que el más bajo está en 10 granos de polen/m³. Por tanto, y debido a su incidencia en la salud humana, es necesario vigilar, entender y predecir la variación temporal y espacial de las concentraciones de gramíneas en la atmósfera.

Las concentraciones de polen de gramíneas en el aire varían principalmente en función de la fuente y de las condiciones meteorológicas. La ciencia que conjuga ambos factores, además de otros relacionados, es la aerobiología, ya que es la rama de la biología responsable de estudiar las partículas orgánicas presentes en el aire. Este campo, por tanto, estudia el origen, comportamiento y distribución temporal y espacial del polen en la atmósfera. En este sentido, las condiciones meteorológicas afectan tanto a su liberación como a su dispersión en la atmósfera. Factores como la temperatura, la humedad, el viento y la lluvia influyen significativamente en la variación temporal y espacial de sus concentraciones [4] [5].

Gracias a los avances en técnicas de muestreo y análisis, se han elaborado calendarios polínicos para alertar a personas sensibles. Para ello además de datos, medidos gracias a instrumentación, se han utilizado y utilizan modelos¹ de previsión de polen atmosférico, como son el SILAM (System for Integrated modeLling of Atmospheric coMposition), uno de los modelos más empleados en Europa y desarrollado por el Instituto Meteorológico Finlandés, o el COSMO-ART, desarrollado por el Instituto Meteorológico Suizo. Actualmente, tanto la complejidad como los cambios de factores meteorológicos, biológicos, geográficos, así como la enorme disponibilidad de datos, están provocando que cada vez más técnicas de muestreo se utilicen y se evalúen nuevas técnicas en la predicción y análisis de la evolución de las concentraciones de pólenes en la atmósfera.

Entre estas técnicas, el *machine learning* ha emergido como una herramienta clave en el desarrollo de modelos predictivos más robustos y adaptativos. El *machine learning* o aprendizaje automático, es una rama de la inteligencia artificial² basada en el entrenamiento de algoritmos³ con datos, con el objetivo de poder realizar predicciones sobre esos mismo datos. Las técnicas de *machine learning* se agrupan en varios tipos de algoritmos especializados en diferentes tareas, como la clasificación, la regresión o agrupación de datos según sus características⁴. La ventaja de esta rama reside en la capacidad de estos modelos en aprender patrones y relaciones complejas sin la necesidad de programar reglas explícitas. La gran capacidad que presentan estos modelos en procesar grandes bancos de información es, además, otro factor positivo en el estudio de fenómenos altamente complejos y caóticos.

¹Término usado para hablar de algoritmos de *machine learning* ya entrenados mediante datos.

²La inteligencia artificial (IA) es una rama de la informática que busca desarrollar sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el reconocimiento de patrones, la toma de decisiones o el aprendizaje a partir de la experiencia.

³Conjunto de pasos o instrucciones bien definidas que permiten resolver un problema o realizar una tarea concreta.

⁴La clasificación consiste en asignar categorías (por ejemplo, detectar si un correo es spam o no), la regresión en predecir valores numéricos (como la temperatura mañana), y la agrupación en encontrar grupos similares dentro de los datos sin etiquetas previas.

La aplicación de estas técnicas se ha extendido rápidamente en campos diversos como la medicina [6], la economía [7] o la biología [8], y su aplicación en el ámbito ambiental ha resultado altamente prometedora. Varios estudios ya han empleado técnicas de *machine learning* en el campo de la aerobiología con gran efectividad. Por ejemplo, se han aplicado estas técnicas en la clasificación automática de tipos de polen [9] [10], así como en la estimación de concentraciones diarias en varias regiones alrededor del mundo, incluyendo los Estados Unidos [11], Grecia [12] y, dentro de España, Málaga [13] y Madrid [14]. Los algoritmos usados en estos artículos abarcan una gran variedad de técnicas predictivas distintas, desde modelos de ensamble hasta árboles de decisión y redes neuronales, mostrando gran rendimiento en sus objetivos.

Bajo este contexto, este trabajo de investigación se enmarca dentro de los estudios que pretenden aportar conocimiento sobre el uso de métodos de *machine learning* en la predicción de concentraciones de polen. Para ello, y gracias a la colaboración con la Red Española de Aerobiología, se han utilizado datos de concentración diaria de polen de gramíneas y de diferentes variables meteorológicas en la ciudad de Córdoba, siendo el primer estudio de este tipo que se realiza en esta ciudad.

Objetivos

El objetivo principal de este trabajo es la evaluación de diferentes métodos de *machine learning* en la predicción de la concentración de polen de gramíneas en la ciudad de Córdoba. Para ello se ha utilizado una base de datos de concentraciones diarias de polen de gramíneas y de variables meteorológicas de 23 años (2001-2023).

Para alcanzar este objetivo principal, se han planteado y alcanzado los siguientes objetivos específicos:

- Selección de modelos representativos de técnicas de *machine learning* supervisadas¹.
- Optimización de los hiperparámetros de cada modelo mediante técnicas de validación cruzada.
- Definición y cálculo de parámetros temporales y de concentración representativos de la evolución del polen de gramíneas.
- Evaluación del rendimiento de cada modelo mediante métricas estadísticas de comparación entre datos observados y modelizados.

¹Variedad de técnica de *machine learning* donde, en el proceso de entrenamiento, los resultados predichos son comparados con los resultados reales ya conocidos.

Metodología

3.1. ZONA DE ESTUDIO

Se ha tomado la ciudad de Córdoba (37.89 N; -4.77 W; 106 m sobre el nivel del mar) como punto de referencia de este estudio. Esta ciudad se localiza al sur de la Península Ibérica, en la comunidad autónoma de Andalucía (Figura 3.1). Su ubicación destaca por su posición en el interior del valle del Guadalquivir, que recorre la comunidad en una orientación de suroeste a nordeste. Al norte, la ciudad limita con la Sierra Morena mientras que al sur se abre hacia la campiña.



Figura 3.1: Zona de estudio. Crédito: Google Earth.

Esta ubicación hace que desde el punto de vista climatológico, la ciudad presente un clima mediterráneo continentalizado con veranos secos y calurosos e inviernos suaves, siendo una de las ciudades en las que se alcanzan de las medias diarias de temperatura más altas del sur de Europa, con máximas superiores a los 40°C.

Por contra, las temperaturas no suelen bajar de los cero grados en invierno. Las precipitaciones, por su parte, se concentran principalmente de octubre a abril, y están comprendidas en el rango entre los 400 y 600 mm al año.

Debido a la ubicación de Córdoba en el interior del valle, los vientos en superficie están condicionados por la orientación del mismo y, por tanto, son principalmente del noreste y sureste, tal y como se muestra en la rosa de vientos representada en la Figura 3.2. Dentro de este rango de direcciones del viento, se alcanza una mayor intensidad en los vientos del oeste. Estacionalmente, diversos estudios [15] han mostrado como en los meses centrales del año el viento sopla principalmente del suroeste, mientras que en los meses más fríos tienen una componente predominante del nordeste.




Figura 3.2: Mapa de frecuencia, velocidad y dirección del viento (*Wind Rose diagram*) superpuesto a un mapa de Córdoba. Crédito: Elaboración propia.

3.2. DATOS

3.2.1. DATOS DE POLEN Los datos de concentración de polen de gramíneas usados en este estudio han sido proporcionados por la Red Española de Aerobiología, los cuales han sido tomados en la estación ubicada en el campus de Rabanales, de la Universidad de Córdoba, siguiendo la metodología definida y descrita por dicha red. Se trata de datos de concentración diaria durante el periodo de 2001 a 2023. La posibilidad de trabajar con 23 años de datos de concentración garantiza una adecuada representatividad de los resultados obtenidos, así como una magnífica oportunidad de entrenar a los métodos de *machine learning* utilizados en este trabajo con datos

que representan diferentes realidades en el comportamiento de las concentraciones de polen.

Una vez recibidos los datos, se aplicó un criterio de calidad a los mismos, a fin de reducir el riesgo de entrenamiento erróneo en base a la consideración de huecos en las series anuales de concentración. De esta forma, aquellos años que no tuvieran un mínimo de 85 % de datos diarios se han eliminado de este estudio. En concreto los años 2004 y 2008 han sido eliminados, tomando finalmente un total de 21 años para este estudio.

La evaluación de los resultados de los diferentes métodos se ha realizado tanto utilizando la serie anual de concentraciones diarias como una serie de parámetros que permiten caracterizar desde un punto de vista temporal y de concentración las series anuales de polen. Para definir estos parámetros se ha establecido el umbral de referencia de 50 granos de polen/m³, al ser el valor más elevado de incidencia de concentración de polen de gramíneas en la salud. Con esta selección, el análisis se centra principalmente en el periodo en el que más población se puede ver afectada por niveles elevados de polen de gramíneas. La definición de los parámetros es la siguiente, mostrándose en la Figura 3.3 un ejemplo gráfico de los mismos:

■ **Parámetros Temporales:**

- **Día de inicio de la estación polínica:** Primer día del año en el que se alcanza una concentración diaria igual o superior a los 50 granos de polen por m³.
- **Día de concentración máxima:** Día del año en el que se alcanza el pico de concentración diaria.
- **Día de finalización de la estación polínica:** Último día del año en el que se registra una concentración diaria de polen superior o igual a 50 granos de polen por m³.

■ **Parámetros de Concentración:**

- **Concentración diaria:** Concentraciones de polen diarias a lo largo del año.
- **Concentración anual:** Suma de concentraciones de polen diarias entre el periodo de inicio y final de la estación polínica.
- **Concentración máxima:** Concentración máxima de polen registrada en el periodo polínico anual.
- **Percentil 95 de concentración:** Valor de concentración correspondiente al percentil 95 durante la estación polínica. Es un valor útil para años en los que el máximo de concentración a lo largo del año es mucho mayor que la concentración promedio del resto de días.




Figura 3.3: Gráfica ilustradora de los días de inicio, final y de concentración máxima, junto con el percentil 95. Representados junto con las concentraciones de polen para el año 2019. Crédito: Elaboración propia.

3.2.2. DATOS METEOROLÓGICOS Los datos meteorológicos utilizados se han tomado de la estación meteorológica de la Red de Información Agroclimática (RIA) de la Junta de Andalucía, ubicada en la ciudad de Córdoba. Esta Red suministra información de las principales variables meteorológicas. Se han tomado datos diarios de las siguientes variables meteorológicas durante el periodo de 2001 a 2023:

- Temperatura máxima (°C)
- Temperatura mínima (°C)
- Temperatura media (°C)
- Humedad relativa (%)
- Dirección del viento (°)
- Precipitación (mm/m³)
- Velocidad del viento (km/h)

La selección de estas variables se basa en su impacto en las concentraciones de polen en la atmósfera. La dirección y velocidad del viento determina el transporte de los granos, las temperaturas altas favorecen la floración y liberación de polen, las precipitaciones ayudan a reducir los granos de polen en la atmósfera y la humedad dificulta la dispersión del polen entre otros.

3.3. Machine learning

El estudio realizado en este trabajo requiere, en su base, un análisis computacional. Por su versatilidad y compatibilidad con técnicas de *machine learning* se ha optado por el lenguaje de programación Python. Debido a la carga computacional asociada al proceso de optimización de los modelos, se ha utilizado el entorno de programación Google Colab, donde los procesos computacionales se realizan en la nube. El código completo utilizado para el análisis y las simulaciones está disponible en: <https://github.com/SylvainHam/TFG-Pollen-Machine-Learning-by-Sylvain-Hamers>

3.3.1. PREPROCESAMIENTO DE DATOS El preprocesamiento de datos es un paso crucial para el entrenamiento de modelos. Sin importar la técnica de *machine learning* usada, si se le proporciona datos incompletos o desbalanceados, las predicciones resultarán pobres. En este sentido, del total de la base de datos utilizada en este trabajo, se han utilizado un 75 % de los años (2001-2016) para entrenar los modelos y un 25 % (2017-2023) para la posterior evaluación de los resultados obtenidos. Bajo esta consideración, se han aplicado las siguientes tres técnicas de preprocesamiento de datos.

Eliminación de los días con datos vacíos

Si en un día faltan datos de algún parámetro, el modelo puede obtener conclusiones erróneas. Para eliminar los días en los que no se tienen datos se han cargado los ficheros de datos con la librería Pandas¹ y se han eliminado los huecos sin datos. Una vez eliminados los días sin datos de las series de concentración de polen, se eliminaron los datos meteorológicos asociados a fin de que siempre exista una pareja de dato de polen y dato meteorológico, ya que el objetivo de las técnicas de *machine learning* usadas va a ser analizar matemáticamente la relación de estos datos a lo largo del periodo de entrenamiento. El hecho de que sea una evolución temporal implica también el objetivo de encontrar relaciones más complejas y realizar predicciones más precisas sobre la ocurrencia y características de la estación polínica.

Normalización de los datos

Para un correcto proceso de entrenamiento de los modelos, se requiere que todas las variables usadas tengan una escala comparable. Si existen variables con rangos de valores muy diferentes (por ejemplo una variable entre 10 y 1000 cm^3 frente a otra entre 0 y 10 m/s^2), los modelos van a tender a dar más importancia a las variables

¹Véase <https://pandas.pydata.org/>

con rangos de valores altos. Este fenómeno se manifiesta especialmente en algoritmos basados en distancias o gradientes.

Para solucionarlo, se usan funciones de escalado y normalización, que transforman los valores de las variables para facilitar el entrenamiento de los modelos. En este estudio se ha usado la función `QuantileTransformer`² de la librería `scikit-learn`³. Esta función transforma la distribución de los datos en una distribución uniforme⁴ en un rango de 0 a 1. La forma en la que se realiza este proceso es buscando los cuantiles de los datos proporcionados y transformando los datos para que los cuantiles sean equidistantes (Figura 3.4). Se ha elegido esta función de normalización debido a la característica que tiene de reducir la importancia de datos extremos. Esto va a permitir a los modelos centrarse en las épocas de polinización y reducir el ruido el resto del año.




Figura 3.4: Ejemplo representativo del funcionamiento de la función `QuantileTransformer`. Crédito: Elaboración propia.

Determinación de los componentes principales

El banco de datos estudiado tiene siete variables meteorológicas⁵, dos variables temporales (mes del año y día del año) y la concentración de polen, teniendo en total 10 dimensiones⁶. Un número alto de dimensiones implica una mayor complejidad en el análisis y, por lo tanto, un proceso de entrenamiento de modelos más costoso computacionalmente.

²Véase [Documentación oficial de la función QuantileTransformer](#).

³Véase <https://scikit-learn.org/stable/index.html>

⁴Distribución de probabilidad donde todos los valores dentro de un rango tienen la misma probabilidad de ocurrir.

⁵Véase 3.2.2 Datos Meteorológicos.

⁶Término usado en ciencia de datos para referirse al número de variables considerados en el análisis.

Para abordar este problema se realiza un análisis de componentes principales. Este proceso busca variables con una gran correlación entre sí y las combina para crear nuevas variables que representan ambas (Figura 3.5). Este proceso conlleva a una reducción de la dimensionalidad de los datos pero también conlleva una pequeña pérdida de información. Generalmente, al hacer este proceso no se pierde más del 15 % de la información original. Para realizar este proceso se ha usado la función PCA⁷ de la librería `scikit-learn`.




Figura 3.5: Figura representativa del proceso de determinación de componentes principales para dos dimensiones. Crédito: Elaboración propia.

3.3.2. TÉCNICAS DE *machine learning* UTILIZADAS En este estudio se han seleccionado tres métodos de *machine learning* para analizar los datos de tres formas diferentes. Debido a la naturaleza de este estudio, todos los métodos elegidos son supervisados, es decir, tienen como objetivo predecir nuevos valores de concentración de polen en base a valores de estos ya conocidos.

Los algoritmos elegidos para este estudio son `KNeighborsRegressor`⁸ (*Nearest Neighbors*), `RandomForestRegressor`⁹ (*Random Forest*) y `MLPRegressor`¹⁰ (red neuronal). Estos fueron elegidos por su frecuente uso en el análisis de datos y sus naturalezas diferentes. A continuación, se describen sus fundamentos teóricos.

⁷Véase <https://scikit-learn.org/stable/modules/decomposition.html#pca>

⁸Véase Documentación oficial del algoritmo `KNeighborsRegressor`.

⁹Véase Documentación oficial del algoritmo `RandomForestRegressor`.

¹⁰Véase Documentación oficial del algoritmo `MLPRegressor`.

Nearest Neighbors

El algoritmo *Nearest Neighbors* (vecinos más cercanos), originalmente introducido por Evelyn Fix y Joseph Hodges en 1951 y documentado oficialmente por Thomas Cover y Peter Hart en 1967 [16], es un modelo basado en la suposición de que los datos con características similares tienden a tener resultados similares. Para realizar una predicción, el modelo busca los datos conocidos cuya distancia al nuevo dato sea menor, y realiza un promedio de sus valores para estimar el resultado del nuevo dato.




Figura 3.6: Representación visual del algoritmo `KNeighborsRegressor` donde se tiene un valor de vecinos más cercanos igual a cinco. Crédito: Elaboración propia.

Por ejemplo, se tiene un conjunto de elementos con valores x , y , z . Se tiene un elemento nuevo con un valor determinado de x e y y se quiere predecir z . Si el algoritmo está modelizado con el hiperparámetro¹¹ `n_neighbors=5`, se van a buscar los cinco elementos conocidos más cercanos al elemento nuevo, se realizará una media de sus valores z y se estimará que el valor z del nuevo elemento es $\bar{z}$ (Figura 3.6).

Random Forest

La técnica *Random Forest* (Bosque aleatorio) introducida por Tin Kam Ho en 1995 [18] es un algoritmo basado en la idea de combinar muchas decisiones simples para llegar a una conclusión más precisa. Su método de funcionamiento es crear grandes árboles de decisión donde cada nodo (u hoja) es una pregunta simple de tipo verdadero/falso; por ejemplo, ¿es la temperatura mayor a 20.4 °C? Cada árbol genera sus preguntas en base a un muestreo aleatorio diferente de los datos proporcionados y ajusta las condiciones de verdadero/falso de cada pregunta de manera automática. A la hora de realizar una predicción se sigue el siguiente procedimiento (figura 3.7):

¹¹Parámetro externo que se debe definir previo al entrenamiento. Véase 3.3.3 Optimización.

1. Se introduce el nuevo dato al algoritmo.
2. Cada árbol evalúa el nuevo dato siguiendo sus propias reglas internas hasta llegar a una conclusión.
3. Se realiza una predicción final calculando el promedio de las conclusiones proporcionados por los árboles.




Figura 3.7: Representación visual del algoritmo RandomForestRegressor. Crédito: [17]

Este algoritmo está basado en el método de *bagging*¹², donde se espera que al realizar el promedio de múltiples árboles de decisión aleatorios se reduzca la varianza y el riesgo de sobreajuste¹³.

Red Neuronal

Las redes neuronales, introducidas inicialmente por Walter Pitts en 1943, son un tipo de algoritmo inspirado en el funcionamiento del cerebro humano. Están formadas por redes de nodos (neuronas) organizadas en capas interconectadas que buscan patrones y relaciones en los datos proporcionados. Los modelos modernos de redes neuronales se basan en la propagación inversa de errores (*backpropagation*), introducido por Seppo Linnainmaa [19] y popularizado en las redes neuronales por el trabajo realizado por David Rumelhart, Geoffrey Hinton y Ronald Williams en 1985 [20]. El proceso de funcionamiento es el siguiente:

¹²Método predictivo introducido por Leo Breiman donde se entrenan varios modelos con muestras aleatorias de datos. [18]

¹³Fenómeno en el análisis de datos donde el modelo se optimiza demasiado en los datos de entrenamiento, resultando en un modelo poco generalizable a datos nuevos.

1. El algoritmo crea capas de nodos aleatorios, el número de capas y nodos en cada capa es decidido de antemano.
2. Se introducen los datos por la red, propagándose por las distintas capas y proporcionando a los nodos un valor inicial. La salida inicial es una combinación homogénea de todos los caminos posibles.
3. La salida inicial se compara con el valor esperado, calculando su error.
4. El error se propaga hacia atrás (*backpropagation*), ajustando los pesos de las conexiones hasta reducir el error al mínimo.




Figura 3.8: Representación visual del algoritmo MLPRegressor. Crédito: [21].

Las capas se distinguen como la capa de entrada, con los datos proporcionados, las capas ocultas - que obtienen su nombre por el hecho de que no se pueden observar directamente los cálculos realizados en las mismas - y la capa de salida donde se realiza la predicción (Figura 3.8).

3.3.3. OPTIMIZACIÓN Los modelos de *machine learning* usados ajustan sus parámetros internos en base a los datos proporcionados. Sin embargo, cada modelo tiene parámetros externos que se deben ajustar previamente al entrenamiento y que determinan el funcionamiento de los algoritmos. A estos parámetros se les llama hiperparámetros y determinan valores dentro de cada modelo, como el número de vecinos más cercanos considerados en el modelo de *Nearest Neighbors* o el número de árboles usados en el modelo *Random Forest*.

El proceso de optimización consiste en determinar los valores de los hiperparámetros que resultan en las mejores predicciones. En este estudio se ha realizado este

proceso mediante la función `GridSearchCV`¹⁴ que ofrece la librería `scikit-learn`. El proceso de funcionamiento de esta función es el siguiente:

1. Se le proporciona a la función un conjunto de valores posibles para cada hiperparámetro.
2. Se generan todas las combinaciones posibles de los valores.
3. Para cada combinación, se separan los datos proporcionados en secciones del mismo tamaño. Para este estudio se ha definido que se separen los datos en tres particiones ($cv=3$).
4. El modelo se entrena sobre dos de las particiones y se evalúa sobre la partición restante. El tipo de evaluación se define mediante el parámetro `scoring`. Para este estudio se ha definido `scoring=None` que corresponde con una evaluación mediante el coeficiente de determinación¹⁵. Se repite esta sección para todas las combinaciones de particiones de entrenamiento y evaluación posibles.
5. Se realiza un promedio de las evaluaciones para cada combinación de hiperparámetros.
6. Una vez evaluadas todas las combinaciones, se genera una tabla con todas las evaluaciones y se selecciona automáticamente la combinación de hiperparámetros que ha proporcionado los mejores resultados.

Cabe destacar que este proceso puede resultar muy costoso a nivel computacional debido a la necesidad de evaluar todas las combinaciones posibles de hiperparámetros. A medida que aumenta el número de hiperparámetros a analizar, aumenta exponencialmente el número de combinaciones posibles. Por esta razón es importante seleccionar cuidadosamente qué parámetros se consideran importantes en la optimización. Por otra parte, el objetivo principal de este trabajo no es la obtención de un modelo perfecto, sino realizar un análisis general de su comportamiento en el contexto de la aerobiología. Por lo tanto el proceso de optimización de los hiperparámetros se ha limitado a un conjunto reducido representativo con el fin de proporcionar una comparación justa entre modelos sin requerir un coste computacional alto.

Por otra parte, todas las optimizaciones se han realizado para maximizar la precisión de las predicciones de polen correspondientes con las concentraciones diarias. Esta decisión se debe a que todos los demás parámetros están calculados en base a las concentraciones diarias, que es el parámetro que más información proporciona sobre las concentraciones de polen de gramíneas.

¹⁴Véase [Documentación oficial de la función GridSearchCV](#)

¹⁵Véase [3.4 Estadísticos utilizados](#).

Número de componentes principales

En este estudio, para reducir carga computacional en el proceso de optimización de los modelos, se ha decidido ajustar este hiperparámetro para uno de los modelos sin optimizar. Por lo tanto, se ha estimado con el método de *Nearest Neighbors* que el valor óptimo de componentes principales son seis (`n_components=6`).

Por otro lado, el análisis del peso atribuido a cada variable permite identificar qué fenómenos climatológicos el modelo considera más relevantes para la predicción de la concentración de polen. En orden de importancia, los datos más influyentes según el modelo son: la precipitación, la dirección del viento, la velocidad del viento, la humedad relativa, la temperatura mínima, el mes del año, el día del año, la temperatura media y, por último, la temperatura máxima. Donde la precipitación tiene el doble de peso que la temperatura máxima.

Hiperparámetros: *Nearest Neighbors*

Los hiperparámetros escogidos tras el proceso de optimización para el modelo `KNeighborsRegressor` en este estudio son los siguientes:

- `n_neighbors`: Determina el número de vecinos más cercanos que se consideran al realizar una predicción. Para este estudio el valor óptimo es 16 vecinos más cercanos.
- `weights`: Controla si se debe ponderar la influencia de cada vecino en función de su distancia al punto a predecir. Para este estudio la configuración óptima es `distance` que asigna mayor peso a los vecinos más próximos.
- `metric`: Determina la métrica usada en el cálculo de la distancia entre los puntos a predecir y sus vecinos más cercanos. Para este estudio la configuración óptima es `manhattan` que corresponde con la geometría del taxista¹⁶.

EL resto de hiperparámetros se han establecido como sus valores predeterminados, se pueden consultar estos valores en la [documentación oficial](#).

Hiperparámetros: *Random Forest*

Los hiperparámetros escogidos tras el proceso de optimización para el modelo `RandomForestRegressor` en este estudio son los siguientes:

- `n_estimators`: Determina el número de árboles en el modelo. Para este estudio el valor óptimo son 200 árboles.

¹⁶Geometría donde la distancia entre dos puntos está definida por la diferencia entre sus coordenadas, en oposición a lo que se postula en la geometría Euclidiana.

- `max_depth`: Determina la profundidad máxima, es decir, el número máximo de condiciones de los árboles. Se aplica al algoritmo para reducir el potencial peso computacional. Para este estudio el valor óptimo son 20 condiciones como máximo para cada árbol.
- `min_samples_leaf`: Determina el número mínimo de muestras que debe tener un nodo final (nodo hoja). Para este estudio el valor óptimo son 2 muestras como mínimo.
- `max_features`: Determina cuántas variables se consideran aleatoriamente en cada división de nodo. Para este estudio la configuración óptima es `sqrt` donde se toma la raíz cuadrada del número total de variables de entrada.

EL resto de hiperparámetros se han establecido como sus valores predeterminados, se pueden consultar estos valores en la [documentación oficial](#).

Hiperparámetros: *Red Neuronal*

Los hiperparámetros escogidos tras el proceso de optimización para el modelo MLPRegressor en este estudio son los siguientes:

- `hidden_layer_sizes`: Determina la arquitectura de la red, es decir, el número de capas ocultas y el número de nodos en las mismas. Para este estudio, el número óptimo es (12, 133), es decir, dos capas ocultas con 12 y 133 nodos respectivamente.
- `activation`: Determina la función matemática aplicada en cada nodo para transformar la información recibida antes de pasarla al siguiente nodo. La configuración óptima para este estudio es `relu` (*Rectified Linear Unit*) que corresponde con una función lineal, es decir, no transforma la información recibida, tan solo determina si propagar la información al siguiente nodo o no.
- `solver`: Determina el algoritmo de optimización aplicado a la distribución de pesos de los nodos para reducir el error. La configuración óptima para este estudio es `adam`¹⁷. El funcionamiento de este algoritmo es complejo, por lo que se recomienda consultar el artículo original [22] en caso de interés.
- `alpha`: Regula la optimización para evitar el *overfitting* introduciendo una penalización a los pesos aplicados. El valor óptimo en este estudio es 0.001 que corresponde con una penalización baja, permitiendo al algoritmo ajustarse a datos con valores extremos.
- `learning_rate_init`: Determina en qué medida se ajustan los pesos de los nodos en cada iteración. Un valor alto puede crear inestabilidad, mientras que un

¹⁷"an algorithm for first-order gradient-based optimization of stochastic objective functions, based on adaptive estimates of lower-order moments" [22]

valor bajo resulta en un aprendizaje lento. El valor óptimo en este estudio es 0.01 indicando que en el aprendizaje se pueden realizar ajustes grandes de los pesos sin perder estabilidad.

- **early_stopping**: Determina si se detiene el ajuste de pesos en caso de, tras varias iteraciones, falta de mejoras en el error. La configuración óptima para este estudio es True, lo que ayuda a evitar *overfitting*.
- **max_iter**: Determina el número máximo de iteraciones en el ajuste de pesos. El número óptimo para este estudio son 1000 iteraciones. Es un número alto pero gracias al hiperparámetro **early_stopping** se espera que el modelo termine el aprendizaje antes de llegar a las 1000 iteraciones.

También se ha de tener en cuenta que el entrenamiento de las redes neuronales está altamente aleatorizado, por lo que al entrenar dos veces un modelo con los mismos hiperparámetros puede llegar a conclusiones diferentes. Esta característica vuelve la optimización muy inconsistente. Para evitar esta aleatoriedad se le asigna un valor al parámetro **random_state**. En este estudio, se le ha proporcionado un valor de 42.

El resto de hiperparámetros se han establecido como sus valores predeterminados, se pueden consultar estos valores en la [documentación oficial](#).

3.4. ESTADÍSTICOS UTILIZADOS

Para evaluar y comparar los resultados obtenidos por cada método con las concentraciones reales medidas se han utilizado los siguientes estadísticos:

- **Coefficiente de determinación (R^2) [23]**: Es un coeficiente que permite comparar cómo de eficiente es el modelo en predecir la variabilidad de las concentraciones. Un modelo que tiende a predecir de manera perfecta obtiene un valor de 1, mientras que un valor de 0 es indicativo de un modelo que no es capaz de reproducir la evolución de los datos observados. Su fórmula es la siguiente¹⁸:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Para calcularlo, se ha empleado la función **r2_score** de la librería **scikit-learn**.

- **Normalized Mean Bias (NMB) [24]**: Es un coeficiente que permite determinar si las predicciones del modelo tienden a sobrestimar o a subestimar los valores

¹⁸Donde y_i son los valores reales, $\hat{y}_i$ las predicciones del modelo, $\bar{y}$ la media de los valores reales y n el número de valores totales.

reales. Sus posibles valores están contenidos entre -1 y 1, donde valores menores a 0 corresponden a subestimaciones, valores mayores a 0 corresponden a sobreestimaciones y 0 corresponde con unas predicciones perfectas. Su fórmula es la siguiente¹⁹:

$$\text{NMB} = \frac{\sum_{i=1}^n (\hat{y}_i - y_i)}{\sum_{i=1}^n y_i} \times 100$$

- **Normalized Mean Error (NME) [24]**: Es un coeficiente que permite determinar cómo de cercanas son las predicciones de los modelos a los valores reales. Se mide en valor absoluto por lo que sus valores posibles están contenidos entre 0 y 1, donde un valor de 0 corresponde con una predicción perfecta, y por el contrario un valor cercano a 1 se corresponde con una predicción más alejada de la real. Su fórmula es la siguiente²⁰:

$$\text{NME} = \frac{\sum_{i=1}^n |\hat{y}_i - y_i|}{\sum_{i=1}^n y_i} \times 100$$

- **Desviación típica (σ) [25]**: Es una medida estadística que mide la variación de un conjunto de datos con respecto a su media. Un valor cercano a 0 indica que los datos tienden a ser cercanos al valor promedio mientras que un valor alto refleja una mayor dispersión de los datos. Su fórmula es la siguiente²¹:

$$\sigma = \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n}}$$

Para calcularlo, se ha empleado la función `std` de la librería `numpy`.

¹⁹Donde y_i son los valores reales, $\hat{y}_i$ las predicciones del modelo y n el número de valores totales.

²⁰Idem.

²¹Donde y_i son los valores individuales, $\bar{y}$ el promedio de los valores y n el número de valores totales.

Resultados

4.1. EVOLUCIÓN TEMPORAL DE LAS CONCENTRACIONES DE POLEN

Esta sección presenta la comparativa entre la evolución real y la obtenida por cada modelo para las concentraciones diarias de polen de gramíneas en la ciudad de Córdoba. En la figura 4.1 se representan las predicciones diarias a lo largo de los años 2017-2023 usando los modelos KNeighborsRegressor (*Nearest Neighbors*), RandomForestRegressor (*Random Forest*) y MLPRegressor (Red Neuronal). Esta figura permite visualizar la capacidad de los modelos en reproducir los patrones estacionales y, por tanto, la estación polínica de las concentraciones de polen de gramíneas.

A nivel general, los modelos han logrado predecir la tendencia general de las concentraciones de polen, centrando sus predicciones en los meses de abril, mayo y junio. Es decir, son capaces de establecer el periodo mensual en el que se registra la estación polínica. El año 2023 es donde se presentan mayores diferencias con respecto a los valores reales, ya que todos ellos retrasan el final de la estación. Este hecho puede deberse a que es el año en el que las concentraciones son las más bajas que se han registrado a lo largo del periodo de estudio. Por su parte, en el año 2021 es en el que se registra un mayor pico de concentración diario de polen de gramíneas, con un valor superior a los 1250 granos de polen por metro cúbico. En este caso, los tres modelos identifican también ese día de elevada concentración pero sin alcanzar una concentración tan elevada. Esta diferencia puede deberse a que se trata, comparado con otros años de una concentración inusualmente alta, y por tanto, puede escapar de los patrones identificados por los modelos en su entrenamiento.




Figura 4.1: Representación de las concentraciones de polen de gramíneas predichas a lo largo de los años 2017-2023 usando los modelos *KNeighborsRegressor* (*Nearest Neighbors*), *RandomForestRegressor* (*Random Forest*) y *MLPRegressor* (Red Neuronal). En color naranja están representadas las concentraciones observadas y en color azul están representadas las concentraciones predichas.

El hecho de que los tres modelos han proporcionado resultados similares en la ocurrencia de valores bajos y altos de concentración muestra que, a pesar de funcionar con algoritmos completamente diferentes, estos modelos interpretan los datos proporcionados de manera similar. La diferencia más notable entre los tres modelos es que las predicciones de la red neuronal presentan menos ruido y muestran patrones de polinización más suaves y focalizados.

A fin de poder establecer un valor estadístico que permita determinar qué modelo representa mejor esta variabilidad anual de las concentraciones diarias de polen de gramíneas, la tabla 4.1 muestra los resultados de calcular el coeficiente de correlación para cada modelo respecto de los datos reales.

Modelo	Coeficiente de determinación R^2
KNeighborsRegressor	0.26
RandomForestRegressor	0.29
MLPRegressor	0.32

Tabla 4.1: Tabla representativa de la precisión de los modelos KNeighborsRegressor (*Nearest Neighbors*), RandomForestRegressor (*Random Forest*) y MLPRegressor (Red Neuronal) según el coeficiente de determinación.

Los valores de coeficiente de determinación obtenidos no son elevados para ningún modelo considerando el periodo total evaluado, estando en un rango de 0.26 para el KNeighborsRegressor y de 0.32 para el MLPRegressor. Por tanto, al estar más próximo a cero que a 1 este resultado indica que los modelos no consiguen captar de manera adecuada la evolución de las concentraciones diarias durante el periodo 2017-2023. La posible razón de estos valores tan bajos puede ser debida al hecho de considerar todo el periodo conjunto, con lo que este parámetro estadístico engloba todos los errores de predicción mencionados anteriormente. En la tabla 4.2 se muestran los resultados de este coeficiente para cada año.

Modelo	Coeficiente de determinación R^2						
	2017	2018	2019	2020	2021	2022	2023
KNeighborsRegressor	0.19	0.39	0.26	0.47	0.37	-1.41	-14.60
RandomForestRegressor	0.21	0.49	0.40	0.32	0.37	-1.70	-11.57
MLPRegressor	0.17	0.41	0.56	0.52	0.42	-1.23	-13.67

Tabla 4.2: Tabla representativa de la precisión de los modelos KNeighborsRegressor (*Nearest Neighbors*), RandomForestRegressor (*Random Forest*) y MLPRegressor (Red Neuronal) según los coeficientes de determinación a lo largo de los años 2017-2023.

Los resultados de esta tabla muestran una elevada variabilidad de este coeficiente entre los diferentes años. Los años que los modelos han conseguido predecir con mejor precisión son 2018, 2019, 2020 y 2021. Para mejor entender estos resultados, hay que tener en cuenta que el coeficiente de determinación mide la precisión de la varianza de los resultados, es decir, a pesar de que en el año 2021 no se ha conseguido predecir el máximo de concentración de polen, los modelos han predicho correctamente los días en los que se tienen concentraciones altas, resultando en un valor de R^2 relativamente alto. Esto también explica la deficiencia de los resultados en el año 2023 donde las predicciones han fallado en predecir la época de polinización.

4.2. COMPARATIVA DE PARÁMETROS TEMPORALES

En esta sección se presenta la comparativa entre los resultados de las predicciones de los parámetros temporales obtenidas de los modelos con los datos reales, es decir, en cada predicción de evolución temporal de cada modelo, se han calculado - para cada año del periodo 2017-2023 - el día de inicio, el de final del periodo polínico, así como el día de concentración máxima; y se han comparado con los reales obtenidos para cada año. Por tanto, se dispone de 7 datos para cada modelo y 7 datos reales de cada parámetro.

La figura 4.2 muestra el valor medio obtenido, y la correspondiente desviación típica, de cada uno de estos parámetros, lo cual permite, a nivel general, observar si los modelos tienen tendencia a sobrestimar o subestimar y cuánto varían sus predicciones con respecto a los datos observados.

Los resultados muestra que las predicciones de los modelos tienden a tener menor variación que los valores reales. Este hecho indica que los modelos tienden a homogeneizar sus predicciones, es decir, estiman que las fechas de inicio, fin y de pico de concentración se mantienen más constantes entre años. Este hecho puede deberse a que no consideran parámetros meteorológicos clave a la hora de, por ejemplo, establecer el inicio de la estación polínica, como es la cantidad de lluvia caída en el invierno previo.

Se comprueba cómo, en promedio, los tres modelos tienden a sobrestimar la fecha de finalización del periodo de polinización de manera notoria. Se observan diferencias entre los 5 y 20 días entre los resultados proporcionados por los modelos y el promedio observado. En el caso de la fecha de comienzo, se obtiene que los modelos `KNeighborsRegressor` y `RandomForestRegressor` tienden a subestimarla, mientras que el modelo `MLPRegressor` tiende a sobrestimar esta fecha. Los tres modelos presentan, en promedio, una buena aproximación a la fecha en la que se registra el pico de concentración anual de polen, siendo el modelo `RandomForestRegressor` el que más se aproxima al promedio real. Combinando estos resultados, sería el modelo `MLPRegressor` el que presenta una mejor respuesta en estos tres parámetros, en consonancia con lo observado en la sección anterior, relativa a la evolución temporal.




Figura 4.2: Gráfica comparativa entre los promedios de los parámetros observados y los promedios de los parámetros predichos por los modelos KNeighborsRegressor (*Nearest Neighbors*), RandomForestRegressor (*Random Forest*) y MLPRegressor (*Red Neuronal*) para los parámetros temporales. Las barras de errores representan la desviación típica de los promedios.

Para establecer de manera numérica cómo los modelos estiman cada uno de los parámetros temporales utilizados, se han calculado los estadísticos NMB y NME entre las parejas de resultados de modelos y los resultados reales. La figura 4.3 muestra los resultados de NMB en el eje X y los resultados obtenidos para el NME en el eje Y. De esta forma, cuanto más alejados estén del eje X resulta en un peor valor del NME mientras que si el punto está a la derecha del eje central significa una sobrestimación y a la izquierda una subestimación del valor real.

Se observa que prácticamente todos los puntos están por debajo del 10% del NME, con la excepción del día de finalización de la época de polen para los modelos KNeighborsRegressor y RandomForestRegressor, que además la sobrestiman ampliamente. De esta forma, el modelo Red Neuronal es aquel que posee mejores resultados en el conjunto de los tres parámetros, aunque eso sí, sobrestimando todos ellos.




Figura 4.3: Comparación de los valores NMB y NME de los parámetros temporales de los modelos `KNeighborsRegressor` (*Nearest Neighbors*), `RandomForestRegressor` (*Random Forest*) y `MLPRegressor` (Red Neuronal).

4.3. COMPARATIVA DE PARÁMETROS DE CONCENTRACIÓN

En esta sección se presentan los resultados obtenidos de comparar los parámetros de concentración de los modelos con los reales, siguiendo el mismo procedimiento que en el caso de los parámetros temporales. De esta forma, y al igual que en la anterior sección, se trabaja con 7 datos para cada modelo de cada uno de los parámetros. La figura 4.4 muestra la comparativa entre los valores medios obtenidos para cada modelo y los datos observados. Se presenta también la desviación típica de cada valor medio.




Figura 4.4: Gráficas comparativas entre los promedios de los parámetros observados y los promedios de los parámetros predichos por los modelos *KNeighborsRegressor* (*Nearest Neighbors*), *RandomForestRegressor* (*Random Forest*) y *MLPRegressor* (*Red Neuronal*) para los parámetros de concentración (véase sección 3.2.1). Las barras de errores representan la desviación típica de los promedios.

Se observa que las barras de desviación son claramente mayores en el caso de los valores reales, tal y como era esperable como consecuencia del pico de concentración registrado en el año 2021. También se observa cómo los tres modelos, en promedio, se comportan de manera muy similar en todos los parámetros. En el caso de la concentración diaria es el parámetro que presenta una mayor similitud con respecto a los valores reales, mientras que en el caso de la concentración total durante el periodo polínico presenta una sobrestimación del promedio real, motivada por el pico de concentración en el año 2021. En el caso de los picos de concentración, los tres modelos presentan una clara tendencia a subestimar los picos de concentración reales. Esta

subestimación se aproxima al valor real en el caso de considerar el percentil 95 de concentración. Esto muestra que estos modelos tienden a suponer épocas de polinización con una menor concentración elevada que las reales. En este caso, y viendo estos resultados es notorio el impacto del pico de concentración de 2021.

La figura 4.5 muestra de manera conjunta los resultados obtenidos para los estadísticos NMB (eje X) y NME (eje Y). Para facilitar la comparativa con los resultados obtenidos para los parámetros temporales, se ha mantenido la escala tanto del NMB como del NME. En este caso, se observa que los modelos tienen a subestimar (NMB negativo) prácticamente todos los parámetros de concentración, y que las diferencias con respecto a los reales (valor de RME) se establecen en porcentajes superiores al 50 %. Las mayores diferencias, con NME superior al 70 % se obtienen para las concentraciones diarias para los tres modelos y la suma de las concentraciones para los modelos KNeighborsRegressor (*Nearest Neighbors*) y RandomForestRegressor (*Random Forest*).




Figura 4.5: Comparación de los valores NMB y NME de los parámetros de concentración de los modelos KNeighborsRegressor (*Nearest Neighbors*), RandomForestRegressor (*Random Forest*) y MLPRegressor (*Red Neuronal*).

4.4. DISCUSIÓN DE LOS RESULTADOS Y CÁLCULO DEL ÍNDICE TOTAL DE PREDICCIÓN

Entre los modelos que en este trabajo se han evaluado, los que presentan una mayor capacidad de abstracción y detección de patrones complejos son MLPRegressor y RandomForestRegressor. En general, ambos han demostrado un mejor rendimiento frente a enfoques más simples basados en similitudes locales como KNeighborsRegressor. Estos resultados sugieren que los fenómenos relacionados con la concentración de polen, influenciados por múltiples factores meteorológicos y estacionales no lineales, son mejor capturados por modelos con una mayor capacidad de generalización. Por tanto, se recomienda que futuras investigaciones se centren en técnicas de *machine learning* más avanzadas, especialmente aquellas basadas en redes neuronales profundas o arquitecturas híbridas, que puedan modelar mejor la variabilidad temporal y los efectos derivados del cambio climático.

De manera individual, el modelo KNeighborsRegressor ha mostrado resultados deficientes en comparación con los otros dos modelos, sin embargo, en el caso en el que se requiera velocidad, este modelo se muestra como el más adecuado debido a su rapidez de entrenamiento (0.04 segundos frente a 4.36 segundos para RandomForestRegressor y 2.90 segundos para MLPRegressor). También es notable que este modelo es el más propenso al sobreajuste, por lo que tiende a generar predicciones más ruidosas y discontinuas.

Por su parte, el modelo RandomForestRegressor ha mostrado resultados favorables en la predicción del día de máxima concentración y resultados promedio para el resto, lo que sugiere que es capaz de capturar ciertas relaciones no lineales relevantes para la predicción de la concentración de polen. Su ventaja principal es la robustez frente al *overfitting* gracias a su método de funcionamiento que combina múltiples árboles de decisión. Destaca como el modelo más lento en el aprendizaje, y, junto con sus resultados promedios, resulta ser un modelo difícilmente recomendable para el estudio meteorológico.

Por último, el modelo MLPRegressor fue el más costoso de optimizar debido al gran número de combinaciones de capas y nodos posibles. Por su naturaleza aleatoria, ha resultado ser también el más inconsistente, requiriendo fijar el parámetro `random_state`. Sin embargo, las redes neuronales han justificado su popularidad, con todas las evaluaciones apuntando a que, en general, son las técnicas de *machine learning* más adecuadas para este estudio.

Una vez visto el comportamiento de cada uno de los modelos, para obtener un marco general de referencia de cómo cada modelo ha pronosticado el conjunto de parámetros utilizados en este trabajo, la tabla 4.3 muestra el valor promedio obtenido al considerar todos los valores de NME y NMB de cada modelo. En este caso, por tanto, se ha aplicado el mismo peso para todos los estadísticos obtenidos.

Los resultados muestran, que en conjunto, los errores son bajos, no superando el 21.64 %, y siendo la red neuronal la que proporciona un valor más bajo, con 18.68 %.

Modelo	Promedio de errores (NMB + NME)
KNeighborsRegressor	21.64 %
RandomForestRegressor	20.02 %
MLPRegressor	18.68 %

Tabla 4.3: Tabla representativa del rendimiento de cada modelo en la predicción de los parámetros elegidos en este estudio. Los modelos son KNeighborsRegressor (*Nearest Neighbors*), RandomForestRegressor (*Random Forest*) y MLPRegressor (Red Neuronal). El valor comparado es el promedio de la suma de los errores *Normalized Mean Bias* (NMB) y *Normalized Mean Error* (NME) de todos los parámetros estudiados.

Conclusiones

El objetivo principal de este trabajo ha sido determinar qué técnicas de *machine learning* resultan más adecuadas para el estudio de las concentraciones de polen de gramíneas. Los resultados muestran que éstas técnicas son muy eficaces en la predicción del inicio, fin y máxima concentración de la época de polinización de gramíneas, teniendo márgenes de errores menores al 10 %. Por otro lado, han mostrado tener dificultades en predecir las concentraciones totales y máximas de estas épocas de polinización. Esta limitación parece deberse a la tendencia de los modelos a asumir una cierta estabilidad interanual en los picos de concentración. Debido a esto, ningún modelo ha sido capaz de predecir el pico excepcional de concentración ocurrido en el año 2021 ni el inicio adelantado de la época de polinización en el año 2023. A pesar de estas limitaciones, las técnicas de *machine learning* han mostrado un gran rendimiento general y se consolidan como una herramienta prometedora para el estudio climatológico.

Para profundizar más en el estudio, se recomienda optimizar más los hiperparámetros de estos modelos, teniendo cuidado de no realizar *overfitting*. Los modelos se beneficiarán también de añadir más años a los datos de entrenamiento, entre ellos, los años 2017-2023 usados en este estudio como fuente de evaluación. Incluir años recientes es especialmente importante debido al impacto del cambio climático en las condiciones meteorológicas y, en consecuencia, en los patrones de polinización. Teniendo esto en cuenta, se recomendaría asignar un mayor peso a los datos más recientes.

Dependiendo del objetivo que se pretende, es posible realizar un estudio de los componentes climatológicos que se podrían omitir para realizar predicciones sin perder precisión o, por lo contrario, estudiar los componentes climatológicos que se podrían añadir para mejorar la precisión de las predicciones. Finalmente, dado el amplio repertorio de técnicas existentes en el campo del *machine learning*, se anima a futuros investigadores a continuar esta línea de estudio, evaluando otras técnicas en la predicción del clima.

Bibliografía

- [1] Rodolfo Rojas Gonzalez, L. (2021). Las 13 alergias más comunes. *muy salud*. Disponible en <https://muysalud.com/enfermedades/alergias-comunes/>
- [2] Ramón Pérez, J., Villamizar, M. (2023). El número de alérgicos al polen se dispara un 42 % en cinco años. *Newtral*. Disponible en <https://www.newtral.es/alergia-polen-espana/20230410/>
- [3] Yvanosky Vázquez Chacón, J. (2023). Gramíneas. *Lifeder*. Disponible en <https://www.lifeder.com/gramineas-poaceae/>
- [4] Carl A. Frisk, Trond Einar Brobakk, Jonathan Rizzi, Hallvard Ramfjord, Influence of spatiotemporal and meteorological variation on Norwegian atmospheric pollen seasonality, *Agricultural and Forest Meteorology*, Volume 353, 2024, 110059, ISSN 0168-1923. <https://doi.org/10.1016/j.agrformet.2024.110059>
- [5] Junhong Zhong, Rongbo Xiao, Peng Wang, Xiaojun Yang, Zongliang Lu, Jiatong Zheng, Haiyan Jiang, Xin Rao, Shuhua Luo, Fei Huang, Identifying influence factors and thresholds of the next day's pollen concentration in different seasons using interpretable machine learning, *Science of The Total Environment*, Volume 935, 2024, 173430, ISSN 0048-9697. <https://doi.org/10.1016/j.scitotenv.2024.173430>
- [6] Oluwaseun Olumide Okundalaye, Necati Özdemir, Richard Olu Awonusika, Early breast cancer prediction using optimized machine learning and tumor-immune modeling, *Journal of Computational and Applied Mathematics*, Volume 473, 2026, 116875, ISSN 0377-0427, <https://doi.org/10.1016/j.cam.2025.116875>
- [7] Sohaib Zahid, Umar Jamil, Data-Driven Machine Learning Techniques for Fuel Economy Prediction in Sustainable Transportation Systems, *Green Energy and Intelligent Transportation*, 2025, 100303, ISSN 2773-1537, <https://doi.org/10.1016/j.geits.2025.100303>
- [8] Weijia Jin, Fangzhong Wang, Lei Chen, Weiwen Zhang, Machine learning-assisted synthetic biology of cyanobacteria and microalgae, *Algal Research*, Volume 86, 2025, 103911, ISSN 2211-9264, <https://doi.org/10.1016/j.algal.2025.103911>

- [9] Nascimento Martins Rodrigues, C., Barbosa Goncalves, A., Pistori, H., Goncalves da Silva, G. (2015). Supervised Machine Learning and Bag of Words applied to Polen Grains Classification. *IEEE Latin America Transactions*, 13(10), 3498–3504. <https://doi.org/10.1109/TLA.2015.7387260>
- [10] Roodschild, M., Gotay Sardiñas, J., Will, A. (2016). Clasificación de granos de polen con Deep Learning y SVM. *Congreso Nacional de Ingeniería en Informática / Sistemas de Información*. Disponible en https://bibliotecas.ucasal.edu.ar/opac_css/index.php?lvl=cmspage&pageid=24&id_notice=61391
- [11] Lo, F., Bitz, C. M., Hess, J. J. (2021). Development of a Random Forest model for forecasting allergenic pollen in North America. *Science of The Total Environment*, 773, 145590. <https://doi.org/10.1016/j.scitotenv.2021.145590>
- [12] Voukantsis, D., Niska, H., Karatzas, K., Riga, M., Damialis, A., Vokou, D. (2010). Forecasting daily pollen concentrations using data-driven modeling methods in Thessaloniki, Greece. *Atmospheric Environment*, 44(39), 5101–5111. <https://doi.org/10.1016/j.atmosenv.2010.09.006>
- [13] Picornell, A., Hurtado, S., Antequera-Gómez, M. L., Barba-González, C., Ruiz-Mata, R., de Gálvez-Montañez, E., Recio, M., Trigo, M. del M., Aldana-Montes, J. F., Navas-Delgado, I. (2024). A deep learning LSTM-based approach for forecasting annual pollen curves: Olea and Urticaceae pollen types as a case study. *Computers in Biology and Medicine*, 168, 107706. <https://doi.org/10.1016/j.combiomed.2023.107706>
- [14] Navares, R., Aznarte, J. L. (2017). What are the most important variables for Poaceae airborne pollen forecasting? *Science of The Total Environment*, 579, 1161–1169. <https://doi.org/10.1016/j.scitotenv.2016.11.096>
- [15] Hernández Ceballos, M. Á., Adame, J., Bolívar, J., Morena, B. (2011). Thermodynamic characteristics of air masses along the Guadalquivir valley determined through the calculation of trajectories. *Tethys Journal of Weather and Climate of the Western Mediterranean*. 8. 21-30. 10.3369/tethys.2011.8.03.
- [16] T. M. Cover, P. E. Hart. (1967) Nearest Neighbor Pattern Classification, *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27.
- [17] Sayed, E. (2025). Mastering Random Forest: A Comprehensive Guide with Detailed Math and Code. Disponible en <https://medium.com/...random-forest...>
- [18] Tin Kam Ho, Random decision forests,"Proceedings of 3rd International Conference on Document Analysis and Recognition, Montreal, QC, Canada, 1995, pp. 278-282 vol.1. <https://doi.org/10.1109/ICDAR.1995.598994>
- [19] Linnainmaa, Seppo (1970). Algoritmin kumulatiivinen pyöristysvirhe yksittäisten pyöristysvirheiden Taylor-kehitemänä. (en finlandés). pp. 6–7.

- [20] Max Jaderberg et al., "Population Based Training of Neural Networks", arXiv pre-print arXiv:1711.09846 (2017).
- [21] Huet, P. (2023). Qué son las redes neuronales y sus aplicaciones. Disponible en <https://openwebinars.net/blog/que-son-las-redes-neuronales-y-sus-aplicaciones/>
- [22] Kingma, D. P., Ba, J. (2017). Adam: A method for stochastic optimization. *Cornell University*. Disponible en <https://arxiv.org/abs/1412.6980>
- [23] A. Colin Cameron, Frank A.G. Windmeijer, An R-squared measure of goodness of fit for some common nonlinear regression models, *Journal of Econometrics*, Volume 77, Issue 2, 1997, Pages 329-342, ISSN 0304-4076, [https://doi.org/10.1016/S0304-4076\(96\)01818-0](https://doi.org/10.1016/S0304-4076(96)01818-0).
- [24] Gustafson, W.I., Jr and Yu, S. (2012), Generalized approach for using unbiased symmetric metrics with negative values: normalized mean bias factor and normalized mean absolute error factor. *Atmosph. Sci. Lett.*, 13: 262-267. <https://doi.org/10.1002/asl.393>
- [25] Bland, J.M.; Altman, D.G. (1996). "Statistics notes: measurement error". *BMJ*. 312 (7047): 1654. <https://doi.org/10.1136/bmj.312.7047.1654>
- [26] Asensio Ramos, A., Cheung, M. C. M., Chifu, I., Gafeira, R. (2023). Machine learning in solar physics. *arXiv preprint*. Disponible en <https://arxiv.org/abs/2306.15308>
- [27] Alcázar, P., Torres, C., De Linares, C., et al. (2024). Impacts of climate change on airborne *Quercus* pollen trends in Andalusia region (southern Spain). *Regional Environmental Change*, 24:50. <https://doi.org/10.1007/s10113-023-02181-5>
- [28] Galarnyk, M. (2017). Principal Component Analysis (PCA) using Python (Scikit-learn). Disponible en https://www.youtube.com/watch?v=kApPBm1YsqU&ab_channel=MichaelGalarnyk
- [29] Gastamina Lasarte, G. (2024). Alergia al polen. Disponible en <https://www.cun.es/enfermedades-tratamientos/enfermedades/alergia-polen>
- [30] Timms, C. I., Liu, X., Zewdie, G. K., Levetin, E. and Lary, D. J. (2018). Machine learning estimation of pollen abundance using Landsat and meteorological data. *Journal of Industrial Pollution and Toxicity*.
- [31] Warmerdam, V. D. (2021). Scikit-learn Crash Course - Machine Learning Library for Python. Disponible en https://www.youtube.com/watch?v=0B5eIE_1vpU&ab_channel=freeCodeCamp.org

[32] Ying, K. (2022). Machine Learning for Everybody – Full Course. Disponible en https://www.youtube.com/watch?v=i_LwzRVP7bg&t=12842s&ab_channel=freeCodeCamp.org